

NLP PROJECT USING TRANSFORMER

Text Summarization using BART Transformer



Hugging Face



python™

Sommaire :

- Text Summarization et l'objectif de notre projet
- Papier de recherche
- Etat de l'art
- L'architecture de BART
- Résultats de nos entraînements.
- Critique de notre projet

C'EST QUOI LA "TEXT SUMMARIZATION" ?

2 APPROCHES :

- **EXTRACTIVE** : sélectionner et assembler des phrases existantes.
- **ABSTRACTIVE** : génère de nouvelles phrases pour transmettre le sens profond.

Input Article

Marseille, France (CNN) The French prosecutor leading an investigation into the crash of Germanwings Flight 9525 insisted Wednesday that he was not aware of any video footage from on board the plane. Marseille prosecutor Brice Robin told CNN that " so far no videos were used in the crash investigation . " He added, " A person who has such a video needs to immediately give it to the investigators . " Robin\'s comments follow claims by two magazines, German daily Bild and French Paris Match, of a cell phone video showing the harrowing final seconds from on board Germanwings Flight 9525 as it crashed into the French Alps . All 150 on board were killed. Paris Match and Bild reported that the video was recovered from a phone at the wreckage site. ...

Text Summarization Models

Abstractive summarization

Extractive summarization

Generated summary

Prosecutor : " So far no videos were used in the crash investigation "


Extractive summary

marseille prosecutor brice robin told cnn that " so far no videos were used in the crash investigation . " robin \'s comments follow claims by two magazines , german daily bild and french paris match , of a cell phone video showing the harrowing final seconds from on board germanwings flight 9525 as it crashed into the french alps . paris match and bild reported that the video was recovered from a phone at the wreckage site .

L'OBJECTIF DE NOTRE PROJET :

- Fine tuning de BART pour de l'**abstractive summarization** sur des **articles d'actualité**, en **Français**.
- Problème de **sequence generation**

Lors d'une manifestation anti-Brexit aux abords du Parlement britannique à Londres, le 17 décembre (...)



résumer par abstractive summarization



Le départ du Royaume-Uni de l'Union européenne, sujet qui déchire les Britanniques, provoque de fortes tensions lors des réunions familiales de fin d'année.



NOTRE PAPIER DE RECHERCHE

BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension


**Mike Lewis*, Yinhan Liu*, Naman Goyal*, Marjan Ghazvininejad,
Abdelrahman Mohamed, Omer Levy, Ves Stoyanov, Luke Zettlemoyer**

Facebook AI

`{mikelewis, yinhanliu, naman}@fb.com`

LLMS


Transformer



Encoder


Decoder

GPT*




Decoder-only

BERT*




Encoder-only

BERT (ENCODEUR)




- LM **bidirectionnel** de Google en 2018
- L'entraînement : **Masked Language Modelin** et **Next Sentence Prediction**
- **classification de texte**, la réponse à des questions courtes (**Q&A**), l'**analyse** de **sentiment**
- Nombreuses variantes : RoBERTa, DistilBERT, ALBERT

GPT (DECODEUR)



- LM **unidirectionnel** développé par OpenAI
- **mécanismes d'attention** pour capturer les relations contextuelles entre les mots
- L'entraînement sur **modélisation de langage**
- traduction automatique du texte, Création de contenu, chatbots et assistants virtuels
- Version : GPT-1, GPT-2, GPT-3, GPT-4

BART



- Architecture **hybride** : bidirectionnel (BERT) + autoregressif (GPT)
- modèle de type **sequence-to-sequence** (seq2seq)
- conçu pour les tâches de : Résumé automatique, Question-answering (QA), Traduction automatique,...


**LEQUEL EST LE PLUS ADAPTÉ À LA TEXT
SUMMARIZATION ?**

COMPARAISON

Modèle	Architecture	Encodage	Capacité de génération	Apprentissage bidirectionnel	Adapté pour le texte summarization
BERT	Encodeur bidirectionnel uniquement	Bidirectionnel	✗ Non conçu pour générer du texte	✓ Oui	✗ Non optimal
GPT	Décodeur autoregressif	Gauche → droite	✓ Oui, génération fluide	✗ Non	⚠ Moyen
BART	Encodeur + Décodeur (comme un Transformer complet)	Encodage bidirectionnel + décodage autoregressif	✓ Oui, via le décodeur	✓ Oui	✓ Oui (très adapté)


BART

Architecture



BART

Masked Language Model



LOSS

Fonction de perte (Loss)

$$\text{Loss}_t = - \sum_{i=1}^V y_{t,i} \log(\hat{y}_{t,i})$$

où :

- V est la taille du vocabulaire,
- $y_{t,i}$ est 1 si le i -ième mot est le mot correct à l'instant t , 0 sinon,
- $\hat{y}_{t,i}$ est la probabilité prédite pour le mot i à l'instant t .

ROUGE SCORES

Metriques de performance

The cat sat on the mat

The cat lay on the mat

ROUGE-1 would identify that five out of the six words match

Fine Tuning Bart pour du text summarization sur des articles d'actualité en Francais

I. Le dataset (kaggle)

	text	summary
0	Jean-Jacques Schuhl, Gilles Leroy, Christian G...	Jean-Jacques Schuhl, Gilles Leroy, Christian G...
1	Une semaine après l'attaque terroriste manquée...	Cette demande intervient une semaine après l'a...
2	Un juge américain a rejeté, jeudi 31 décembre,...	Un juge américain a rejeté jeudi les accusatio...
3	Un attentat a fait au moins 93 morts et plusie...	Un kamikaze a fait exploser sa voiture piégée ...
4	Cinq personnes sont mortes, et treize autres o...	Cinq personnes sont mortes, et treize autres o...
...	...	...
392897	Seules les personnes employées par des particu...	Dès le mois de janvier, l'impôt sera désormais...
392898	Carlos Ghosn à Paris, le 6 octobre 2017. MICHE...	L'ex-président du constructeur japonais Nissan...
392899	Lors d'une manifestation anti-Brexit aux abord...	Le départ du Royaume-Uni de l'Union européenne...
392900	La chancelière allemande Angela Merkel, peu ap...	Il appartient à Berlin de « tenir bon, argumen...
392901	Depuis Noël, ils sont une centaine de migrants...	Il consiste notamment en un accroissement du n...


Texte : Lors d'une manifestation anti-Brexit aux abords du
Parlement britannique à Londres, le 17 décembre (...)

Résumé : Le départ du Royaume-Uni de l'Union européenne,
sujet qui déchire les Britanniques, provoque de fortes tensions
lors des réunions familiales de fin d'année.

Nombre de textes : 392902
Moyenne de mots dans 'text' : 520.96
Moyenne de mots dans 'summary' : 24.84

Fine Tuning Bart pour du text summarization sur des articles d'actualité en Francais

II. Data split



III. Implémentation



Arguments d'entraînement



```
import transformers

# Définir les arguments de l'entraînement
training_args = transformers.Seq2SeqTrainingArguments(
    output_dir='./bart_finetuning_results',
    evaluation_strategy='epoch',           # Evaluation après chaque époque
    learning_rate=2e-5,                   # learning rate
    per_device_train_batch_size=8,         # Taille du batch pour l'entraînement
    per_device_eval_batch_size=8,         # Taille du batch pour l'évaluation
    save_total_limit=3,                   # Nombre maximal de checkpoints à conserver
    num_train_epochs=3,                   # Nombre d'époques d'entraînement
    predict_with_generate=True            # Utiliser la fonction de génération pour les prédictions
)
```



```
trainer = transformers.Seq2SeqTrainer(
    model=model,                          # modèle BART
    args=training_args,                   # Les arguments d'entraînement
    train_dataset=tokenized_df['train'],  # dataset d'entraînement tokenisé
    eval_dataset=tokenized_df['test'],    # dataset de test tokenisé
    tokenizer=tokenizer,                  # Le tokenizer de BART
    data_collator=data_collator,          # La fonction de préparation des données pour l'entraînement
    compute_metrics=compute_metrics       # La fonction pour évaluer les résultats avec ROUGE
)

trainer.train()
```


BART LARGE sur 3 epochs (20 heures)




BART Base sur 3 epochs (10 heures)






BART LARGE sur 3 epochs



BART Base sur 3 epochs



BART Base sur 10 epochs (20 heures)



Rouge Score 1 (couverture lexicale)

Exemple:

- **référence** : Le chat dort sur le canapé.
- **résumé généré** : Le chat dort.

$$\text{Recall} = \frac{\text{Nombre de n-grammes communs entre le résumé généré et la référence}}{\text{Nombre total de n-grammes dans la référence}} = \frac{3}{6} = 0.5$$

$$\text{Precision} = \frac{\text{Nombre de n-grammes communs entre le résumé généré et la référence}}{\text{Nombre total de n-grammes dans le résumé généré}} = \frac{3}{3} = 1.0$$

$$\text{F1}_{\text{ROUGE-1}} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = 2 \times \frac{0.5 \times 1.0}{0.5 + 1.0} = 0.6667$$

Rouge Score 2 (cohérence locale)

Exemple :

- **référence** : Le chat dort sur le canapé.
- **résumé généré** : Le chat dort.
- (Le chat), (chat dort), (dort sur), (sur le), (le canapé)
- (Le chat) , (chat dort)

$$\text{Recall}_{ROUGE-2} = \frac{\text{nombre de bigrammes communs}}{\text{nombre total de bigrammes dans la référence}} = \frac{2}{5} = 0.4$$

$$\text{Precision}_{ROUGE-2} = \frac{\text{nombre de bigrammes communs}}{\text{nombre total de bigrammes dans le résumé généré}} = \frac{2}{2} = 1.0$$

$$\text{F1}_{ROUGE-2} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = 2 \times \frac{0.4 \times 1.0}{0.4 + 1.0} \approx 0.5714$$

Rouge Score L (respect de la structure globale)

Exemple:

- **référence** : Le chat dort sur le canapé.
- **résumé généré** : Le chat dort.

LCS = le chat dort = 3

$$\text{Recall}_{\text{ROUGE-L}} = \frac{\text{Longueur du LCS}}{\text{Longueur totale de la référence}} = \frac{3}{6} = 0.5$$

$$\text{Precision}_{\text{ROUGE-L}} = \frac{\text{Longueur du LCS}}{\text{Longueur totale du résumé généré}} = \frac{3}{3} = 1.0$$

$$\text{F1}_{\text{ROUGE-L}} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = 2 \times \frac{0.5 \times 1.0}{0.5 + 1.0} \approx 0.6667$$

Rouge Score L sum (respect de la structure globale)


Identique que Rouge Score L mais pour tout le texte entier.

$$\text{Recall}_{ROUGE-Lsum} = \frac{\text{Longueur du LCS sur tous les documents}}{\text{Longueur totale de la référence}}$$


$$\text{Precision}_{ROUGE-Lsum} = \frac{\text{Longueur du LCS sur tous les documents}}{\text{Longueur totale du résumé généré}}$$

$$\text{F1}_{ROUGE-Lsum} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Score Rouges BART LARGE




Fine tuning sur 3 epochs




Modèle original




Score Rouges BART Base



Fine tuning sur 10 epochs



Fine tuning sur 3 epochs



Modèle original





Fine tuning BART BASE sur 10 epochs



Fine tuning BART Large sur 3 epochs



Fine tuning BART Base sur 3 epochs



BART Large



BART Base

Conclusion



- Meilleur résultat sur notre fine-tuning.



- Entraînement trop long pour BART Large.
- Pas assez d'epochs pour une convergence totale.
- Scores ROUGE $< 0,5$.
- Se focaliser uniquement sur BART Base.

Impacts sur la société



- **Accès à l'information** sur l'actualité plus facilement.
- Utilité pour les **influenceurs médiatiques** qui travaillent sur des actualités.



- **Baisse de l'attention** et de la capacité de **concentration** des lecteurs.
- Risque d'**appauvrissement** de l'**information** et du **contexte**.
- **Consommation énergétique importante** du fine-tuning et de la summarization text.